

LAPORAN PRAKTIKUM



Machine Learning Instalasi Jupyter Notebook – Instalasi Jupyter Notebook dan Load Data

IDENTITAS

Nama Lengkap	:	Fahri Mulyadi
NIM	:	0110225156
Program Studi	:	Teknik Informatika
Mata Kuliah	:	Machine Learning
Dosen Pengampu	:	Dr. Sirojul Munir, S.Si., M.Kom.
Asisten Dosen/Lab	:	Elyas Randi Renaldi
Tanggal Praktikum	:	14 september 2026

Daftar Isi

LAPORAN PRAKTIKUM.....	1
IDENTITAS.....	1
Daftar Gambar.....	3
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Tujuan Praktikum	4
BAB II LANDASAN TEORI.....	5
2.1 Machine Learning.....	5
2.2 Dataset.....	5
2.2.1 Data Kategorikal / Kualitatif (<i>Categorical</i>)	6
2.2.2 Data Numerik / Kuantitatif (<i>Numerical</i>)	6
2.2.3 Berdasarkan Bentuk Fisik Data.....	6
2.2.1 Struktur Dataset	6
2.2.2 Atribut dalam Dataset.....	7
2.2.3 Analisis Data dalam Konteks Machine Learning.....	7
2.3 Lingkungan dan Tools Machine Learning	7
2.3.1 Python (Bahasa Pemrograman Utama)	7
2.3.2 Jupyter Notebook / Google Colab (Interactive Development Environment).....	8
2.3.3 Anaconda & Conda / Pip (Manajemen Paket & Environment)	8
BAB III METODOLOGI PRAKTIKUM.....	9
3.1 Dataset yang Digunakan.....	9
3.2 Tahapan Praktikum	9
BAB IV HASIL DAN PEMBAHASAN.....	12
4.1 Hasil Instalasi dan Konfigurasi	12
4.2 Hasil Loading Dataset.....	12
4.3 Hasil Eksplorasi Awal Dataset.....	13
4.4 Pembahasan.....	13
BAB V KESIMPULAN DAN SARAN	14
5.1 Kesimpulan	14
5.2 Saran	14
DAFTAR PUSTAKA	15

Daftar Gambar

gambar 1 proses ter- <i>connect</i> dengan <i>goggle drive</i>	12
gambar 2 proses <i>load</i> data.....	12
gambar 3 proses Ekspolasi data.....	13

BAB I PENDAHULUAN

1.1 Latar Belakang

Dalam era digitalisasi saat ini, penerapan *Machine Learning* dan *Data Science* telah menjadi inti dalam memecahkan masalah komputasi yang kompleks, mulai dari analisis prediktif hingga pengenalan pola. Pengembangan model *Machine Learning* modern membutuhkan lingkungan komputasi yang tidak hanya mampu mengeksekusi algoritma dengan cepat, tetapi juga interaktif. Lingkungan yang interaktif ini penting karena alur kerja kecerdasan buatan—yang meliputi tahap eksplorasi data, pra-pemrosesan, hingga pelatihan model—bersifat sangat iteratif dan memerlukan evaluasi secara visual [1].

Pertumbuhan volume data yang sangat pesat (*data explosion*) pada berbagai sektor industri mengubah tantangan utama organisasi: dari kekurangan data menjadi keterbatasan dalam mengolah data berdimensi tinggi. Pengambilan keputusan konvensional yang mengandalkan intuisi atau analisis deskriptif sederhana terbukti memiliki keterbatasan saat berhadapan dengan pola data yang kompleks dan non-linear [2].

Ketidakmampuan menganalisis pola tersembunyi secara cepat berpotensi meningkatkan risiko kesalahan pengambilan keputusan. Oleh karena itu, arsitektur *Decision Support System* (DSS) modern membutuhkan integrasi *Machine Learning* untuk mentransformasi data mentah menjadi wawasan yang dapat ditindaklanjuti (*actionable insights*) [3].

1.2 Tujuan Praktikum

Tujuan Umum:

Tujuan Umum: Memberikan pemahaman awal mengenai konsep dan lingkungan kerja *Machine Learning* melalui proses instalasi tools serta pemuatan dataset untuk keperluan analisis dan pengolahan data.

Tujuan Khusus:

1. Memahami konsep dasar *Machine Learning*.
2. Melakukan instalasi dan konfigurasi tools.
3. Memuat dataset ke dalam lingkungan kerja.
4. Memahami struktur dan karakteristik awal dataset.

BAB II LANDASAN TEORI

2.1 Machine Learning

Machine Learning (ML) adalah subbidang dari Kecerdasan Buatan (*Artificial Intelligence / AI*) yang berfokus pada pengembangan algoritma agar sistem komputasi dapat mempelajari pola secara otomatis dari data dan meningkatkan akurasi kinerjanya tanpa perlu diprogram secara eksplisit [4].

Dalam pemrosesan data, Machine Learning bekerja dengan memetakan hubungan antara variabel input (*features*) dan variabel output (*target*) menggunakan kerangka matematis dan statistik [5].

Terdapat empat pilar utama dalam konsep dasar Machine Learning saat digunakan untuk mengolah data:

- 2.1.1 **Data dan Fitur (*Features*):** Data mentah diekstraksi menjadi fitur (karakteristik atau atribut kuantitatif) yang merepresentasikan informasi penting untuk dipelajari oleh algoritma.
- 2.1.2 **Pelatihan (*Training*) dan Pengujian (*Testing*):** Dataset umumnya dibagi menjadi dua bagian: *training set* untuk membentuk model, dan *test set* untuk menguji sejauh mana model mampu menggeneralisasi data baru yang belum pernah dilihat sebelumnya.
- 2.1.3 **Paradigma Pembelajaran:**
 - **Supervised Learning:** Algoritma dilatih menggunakan data yang memiliki pasangan input dan label target (misalnya untuk klasifikasi dan regresi) [5].
 - **Unsupervised Learning:** Algoritma mengolah data tanpa label untuk menemukan struktur atau kelompok alami di dalam data (misalnya klusterisasi dan reduksi dimensi).
 - **Reinforcement Learning:** Model (*agent*) belajar mengambil keputusan melalui interaksi dengan lingkungan berbasis sistem *reward* dan *penalty*.
- 2.1.4 **Evaluasi Performa:** Mengukur tingkat keandalan dan akurasi model menggunakan *evaluation metrics* seperti *Accuracy*, *Precision*, *Recall*, *F1-Score*, atau *Mean Squared Error (MSE)*.

Tujuan utama penerapan **Machine Learning (ML)** dalam pengolahan dan analisis data adalah memproses himpunan data yang kompleks, mengekstrak pola implisit, serta membangun pemodelan prediktif guna mentransformasi data mentah menjadi wawasan yang dapat ditindaklanjuti (*actionable insights*) [4].

2.2 Dataset

Dataset (himpunan data) adalah kumpulan informasi atau data yang saling berhubungan, terstruktur, dan diorganisasi sedemikian rupa agar dapat diproses, dianalisis, atau dipelajari oleh computer [6].

Dalam konteks *Machine Learning* dan analisis data, dataset merepresentasikan himpunan sampel atau observasi yang digunakan untuk menemukan pola (*pattern discovery*), melatih model (*model training*), serta menguji performa prediksi (*model testing*) [7].

Secara umum, tipe data yang menyusun dataset dikelompokkan berdasarkan sifat nilai dan tingkat pengukurannya [6]:

2.2.1 Data Kategorikal / Kualitatif (*Categorical*)

Data berupa nilai diskrit yang merepresentasikan kelompok, label, atau kategori:

- **Nominal:** Kategori murni tanpa ada tingkatan atau urutan logis. Contoh: jenis kelamin (**Pria, Wanita**), warna mata, atau status pernikahan.
- **Ordinal:** Kategori yang memiliki tingkatan, urutan, atau skala hirarki yang jelas, namun jarak antar-kategori tidak dapat dihitung secara pasti. Contoh: tingkat pendidikan (**SD, SMP, SMA, S1**) atau tingkat kepuasan pelanggan (**Kurang, Cukup, Puas**).

2.2.2 Data Numerik / Kuantitatif (*Numerical*)

Data berupa angka kuantitatif yang dapat dioperasikan secara matematis:

- **Diskrit (*Discrete*):** Nilai berupa bilangan bulat hasil dari perhitungan/pencacahan. Contoh: jumlah anak dalam keluarga, jumlah transaksi harian, atau jumlah klik pada situs web.
- **Kontinu (*Continuous*):** Nilai riil (dapat berupa desimal) hasil dari pengukuran yang berada dalam rentang tertentu. Contoh: suhu udara, tinggi badan, berat badan, atau harga saham.

2.2.3 Berdasarkan Bentuk Fisik Data

- **Terstruktur (*Structured*):** Memiliki format tabel yang rapi berupa baris dan kolom (seperti berkas **.csv**, **.xlsx**, atau tabel basis data SQL).
- **Semi-terstruktur (*Semi-structured*):** Memiliki penanda (*tag*) atau struktur internal tetapi tidak berbentuk tabel kaku (seperti JSON atau XML).
- **Tidak Terstruktur (*Unstructured*):** Data tidak memiliki struktur kaku atau hirarki tetap (seperti teks bebas, berkas audio, citra/gambar, dan video).

Struktur dan atribut dalam dataset membentuk fondasi dasar sebelum proses analisis data maupun pemodelan *Machine Learning* dilakukan. Berikut adalah penjelasan terstruktur beserta referensi jurnal ilmiah yang valid.

2.2.1 Struktur Dataset

Secara umum, dataset terstruktur direpresentasikan dalam bentuk matriks dua dimensi yang terdiri dari baris dan kolom [8]:

- **Baris (Rows / Instances / Records / Samples):** Merepresentasikan objek, sampel, atau kejadian individual yang diamati dalam satu kesatuan.
- **Kolom (Columns / Features / Attributes / Variables):** Merepresentasikan karakteristik, sifat, atau properti tertentu yang diukur dari setiap objek.

2.2.2 Atribut dalam Dataset

Atribut adalah karakteristik atau variabel yang mendefinisikan sifat dari sebuah objek data [6]. Berdasarkan perannya dalam pemodelan *Machine Learning*, atribut dibagi menjadi:

- **Atribut Input (Features / Independent Variables):** Variabel masukan yang digunakan oleh algoritma untuk mempelajari pola.
- **Atribut Target (Label / Dependent Variable):** Variabel luaran atau hasil yang ingin diprediksi oleh model (*supervised learning*).
- **Atribut Identifikasi (ID):** Atribut penanda keunikan entitas yang umumnya disingkirkan sebelum analisis karena tidak memiliki nilai prediktif.

2.2.3 Analisis Data dalam Konteks Machine Learning

Analisis data adalah proses inspeksi, pembersihan (*cleaning*), transformasi, dan pemodelan data untuk menemukan informasi bermakna dan mendukung pengambilan keputusan [7]. Dalam alur kerja *Machine Learning*, analisis data dibagi menjadi beberapa tahap utama:

- **Analisis Eksplorasi Data (Exploratory Data Analysis / EDA):** Memeriksa distribusi statistik dasar, korelasi antar-atribut, dan mendeteksi adanya nilai yang hilang (*missing values*) atau data anomali (*outliers*).
- **Transformasi & Rekayasa Fitur (Feature Engineering):** Menyiapkan struktur atribut agar sesuai dengan algoritma (misalnya normalisasi skala data numerik dan *encoding* data kategorikal).
- **Analisis Prediktif & Penemuan Pola:** Menerapkan model matematika untuk mengekstrak pola tersembunyi atau menghasilkan estimasi nilai di masa depan guna mendukung sistem pengambil keputusan (*Decision Support System*).

2.3 Lingkungan dan Tools Machine Learning

Lingkungan pemrograman dan ekosistem tools dalam praktikum Machine Learning (ML) dirancang untuk memfasilitasi seluruh alur kerja olah data—mulai dari ekstraksi data mentah, pembersihan, eksplorasi pola, hingga pelatihan dan evaluasi model prediktif [9].

2.3.1 Python (Bahasa Pemrograman Utama)

Python menjadi bahasa standar defakto dalam pengembangan *Machine Learning* karena sintaksnya yang ringkas, fleksibilitas tinggi, serta dukungan ekosistem pustaka (*libraries*) analitis yang sangat luas [10].

2.3.2 Jupyter Notebook / Google Colab (Interactive Development Environment)

Jupyter Notebook adalah lingkungan komputasi interaktif berbasis *web* yang memungkinkan integrasi kode eksekusi, teks dokumentasi (*Markdown*), rumus matematika, dan visualisasi data dalam satu dokumen tunggal `.ipynb` [11].

- **Fungsi Utama:** Menganalisis data secara bertahap (*block-by-block execution*) sehingga mempermudah proses eksperimentasi dan pemeliharaan alur data.

2.3.3 Anaconda & Conda / Pip (Manajemen Paket & Environment)

Distribusi Python yang menyediakan manajer paket (`pip` atau `conda`) untuk menginstal, mengisolasi *environment*, dan mengelola kompatibilitas *library* komputasi ilmiah secara konsisten.

BAB III METODOLOGI PRAKTIKUM

3.1 Dataset yang Digunakan

Dataset yang digunakan dalam penelitian/praktikum ini merupakan data sekunder yang bersumber dari repositori publik (*Kaggle Machine Learning*) [12]. Penggunaan data sekunder yang terpilih bertujuan untuk memastikan keterandalan sampel data yang telah tervalidasi secara baku untuk pengujian algoritma [13].

Pengambilan datasetnya:

- Nama file: *Day.csv*
- Jumlah observasi/sampel: 731
- Jumlah atribut: 16

Berdasarkan format penyimpanan dan karakteristik nilai variabelnya, data yang diolah dikategorikan sebagai **data terstruktur (*structured data*)** [14]. Tipe variabel di dalam dataset ini dikelompokkan menjadi dua kategori utama [12]:

➤ **Data Numerik / Kuantitatif:**

- **Kontinu:** Variabel bernilai riil atau desimal dari hasil pengukuran spasial/fisik (contoh: *temp, atemp, hum, windspeed*).
- **Diskrit:** Variabel bernilai bilangan bulat dari hasil pencacahan (contoh: *casual, registered, cnt, instant*).

➤ **Data Kategorikal / Kualitatif:**

- **Nominal:** Kategori data tanpa urutan atau hierarki antarnilai (contoh: *holiday, workingday, yr*).
- **Ordinal:** Kategori data yang memiliki tingkatan atau urutan rentang yang jelas (contoh: *season, mnth, weekday, weathersit*).

Dataset terstruktur direpresentasikan dalam bentuk matriks data dua dimensi berukuran N times P , di mana N mewakili jumlah baris (sampel observasi) dan P mewakili jumlah kolom (atribut/variabel) [14].

3.2 Tahapan Praktikum

Tahapan praktikum yang dilakukan meliputi:

- Membuat folder di *goggle drive* yang berisikan di dalam nya yaitu:- folder *data*, folder *models*, folder *notebook* dan folder *report*.
- Masukkan dataset yang sudah dibuat dengan format "*day.csv*" ke dalam folder *data*.
- Buat *file* di dalam folder *notebook*.

- Sambungkan/connect-kan *goggle colaburation (G-colab)* yang sudah dibuat di folder *notebook* dengan *command*:

- `from google.colab import drive`

- `drive.mount('/content/drive')`

dan *running* secara otomatis akan ter-connect.

- Setelah itu masukkan lagi *command* untuk mengimpor dataset yang tadi disimpan di folder data.

- `import pandas as pd`

- `df =`

```
pd.read_csv("/content/drive/MyDrive/ML_2026/praktikum_01/Data/day.csv")
```

- `df.head()`

lalu *running*. Agar terimpor dengan benar yaitu harus men-setting cari icon 'file'

->sambungkan dengan dataset .csv yang disimpan di folder data ->Nanti langsung muncul datasetnya.

instant	date	season	month	holiday	weekend	workingday	weather	temp	atemp	hum	windspeed	casual	registered	count		
0	1	2011-01-01	1	0	1	0	6	0	2	0.344167	0.363625	0.805833	0.160446	331	654	985
1	2	2011-01-02	1	0	1	0	0	0	2	0.363478	0.353739	0.696087	0.248539	131	670	801
2	3	2011-01-03	1	0	1	0	1	1	1	0.196364	0.189405	0.437273	0.248309	120	1229	349
3	4	2011-01-01	1	0	1	0	2	1	1	0.200000	0.212122	0.590435	0.160296	108	1454	562


instant	date	season	month	holiday	weekend	workingday	weather	temp	atemp	hum	windspeed	casual	registered	count
	-	04												
	20													
	11													
4	5	-	1	0	1	0	3	1	1	0.22	0.22	0.4		
	01									69	92	369		
	-									57	70	5		
	05													

- Lanjut ketik *comand*
- `df.columns`
untuk melihat seluruh nama kolom (atribut) yang ada di dalam objek *DataFrame* (df) lalu *running*.
- Lalu masukkan *comand*
- `df.shape`
untuk mengetahui dimensi atau ukuran dari sebuah *DataFrame* (jumlah baris dan jumlah kolom) lalu *running*.
- Lalu masukkan *comand*
- `df.info()`
untuk melihat ringkasan informasi teknis dan struktur internal dari sebuah *DataFrame* secara lengkap. Lalu *running*,
- Lalu masukkan *comand*
- `df.duplicated().value_counts()`
untuk menghitung total baris duplikat (data ganda) dan baris unik di dalam *DataFrame*. Lalu *running*.
- Lalu masukkan *comand*
- `df.isnull().sum()`
untuk menghitung total nilai yang hilang atau kosong (*missing values / NaN*) pada setiap kolom di dalam *DataFrame*. Lalu *running*.
- Lalu masukkan *comand*
- `df['weathersit'].unique()`
untuk menampilkan daftar seluruh nilai unik (berbeda) yang ada di dalam kolom *weathersit* tanpa perulangan/duplikat. Lalu *running*.

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Instalasi dan Konfigurasi


Dataset yang sudah selesai dibuat lalu proses selanjutnya itu adalah yang mengimpor supaya terhubung antara *goggle colab* dengan *goggle drive* kita.



gambar 1 proses ter-connect dengan goggle drive

4.2 Hasil Loading Dataset

Hasil pemuatan data ini ter-connect kedalam *goggle drive*. lalu langkah selanjutnya itu mengimpor dataset yang tadi di simpan di folder data agar dapat di akses datanya dan muncul di dalm *goggle colab* tersebut.



gambar 2 proses load data

4.3 Hasil Eksplorasi Awal Dataset

Berikut merupakan struktur, jumlah data, atribut, dan beberapa contoh data dari dataset yang digunakan.

index	instant	dteday	season	yr	mmth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01	1	0	1	0	6	0	2	0.344167	0.363625	0.805833	0.160446	331	654	985
1	2	2011-01-02	1	0	1	0	0	0	2	0.363476	0.353739	0.894687	0.248039	131	670	801
2	3	2011-01-03	1	0	1	0	1	1	1	0.196364	0.189405	0.437273	0.248309	120	1229	1349
3	4	2011-01-04	1	0	1	0	2	1	1	0.212122	0.590435	0.160296	0.160296	108	1454	1562
4	5	2011-01-05	1	0	1	0	3	1	1	0.226957	0.22927	0.436957	0.1869	82	1518	1600

Show 25 per page
Like what you see? Visit the [data lab notebook](#) to learn more about interactive tables.

gambar 3 proses Ekspolasi data

4.4 Pembahasan

Hasil eksplorasi dan diagnostik terhadap dataset (`day.csv`) memberikan pijakan kritis dalam merancang alur kerja *Machine Learning* yang valid dan efisien. Berdasarkan inspeksi dimensi dan kebersihan data melalui perintah `df.shape`, `df.info()`, `df.isnull().sum()`, serta `df.duplicated().value_counts()`, seluruh 731 sampel observasi harian terbebas dari nilai kosong (*missing values*) maupun rekaman duplikat. Kondisi data yang bersih ini mengonfirmasi bahwa tahapan imputasi data (*data imputation*) dan pembersihan data ganda tidak perlu dilakukan pada tahap pra-pemrosesan awal.

Namun, temuan diagnostik paling krusial terletak pada hubungan linier mutlak antara variabel target `cnt` dengan atribut `casual` dan `registered`. Karena jumlah total penyewaan merupakan hasil penjumlahan langsung dari kedua variabel tersebut ($cnt = casual + registered$), pengeluaran atribut `casual` dan `registered` dari matriks fitur masukan (X) menjadi langkah imperatif. Jika kedua atribut tersebut tetap dipertahankan saat pelatihan model, sistem akan mengalami *data leakage* (kebocoran informasi target) yang mengakibatkan evaluasi akurasi model menjadi tidak obyektif. Selain itu, atribut `instant` juga dieliminasi dari pemodelan karena hanya berfungsi sebagai indeks rekaman tanpa bobot prediktif.

BAB V KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan seluruh rangkaian tahapan praktikum yang telah dilakukan, dapat ditarik beberapa kesimpulan utama sebagai berikut:

- **Inisialisasi Lingkungan Kerja:** Integrasi antara *google colab* dan *google drive* berhasil dikonfigurasi secara optimal, memungkinkan proses pemuatan dataset `day.csv` ke dalam memori kerja menggunakan pustaka *Pandas* berjalan dengan lancar.
- **Karakteristik dan Kebersihan Data:** Hasil eksplorasi awal melalui perintah diagnostik *Pandas* (`df.shape`, `df.info()`, `df.isnull().sum()`, `df.duplicated().value_counts()`, dan `df['weathersit'].unique()`) menunjukkan bahwa dataset terdiri atas 731 sampel observasi harian dan 16 atribut terstruktur yang bersih dari nilai kosong (*missing values*) maupun rekaman duplikat.
- **Persiapan Pemodelan *Machine Learning*:** Identifikasi hubungan matematis mutlak $\text{cnt} = \text{casual} + \text{registered}$ menegaskan perlunya eliminasi atribut *casual*, *registered*, dan *instant* guna mencegah *data leakage*. Karakteristik fitur yang terstruktur dengan baik memberikan landasan yang valid untuk melanjutkan ke tahap pemodelan regresi atau klasifikasi dalam pembangunan Sistem Pendukung Keputusan (*Decision Support System / DSS*).

5.2 Saran

Berdasarkan hasil pengamatan awal dan pembahasan terhadap dataset `day.csv`, berikut adalah beberapa saran teknis untuk tahapan pengolahan serta analisis data lebih lanjut menggunakan metode *Machine Learning*:

- **Rekayasa Fitur Waktu:** Menerapkan *cyclical encoding* ($\sin$ dan $\cos$) pada variabel tanggal (`dteday`) untuk menangkap pola musiman secara presisi.
- **Eksperimentasi Algoritma:** Membandingkan performa model regresi (*Random Forest*, *XGBoost*) dan klasifikasi tingkat permintaan sepeda.
- **Optimasi & Validasi:** Menggunakan *Time-Series Split Cross-Validation* dan *Grid Search* untuk pengujian kronologis dan optimasi *hyperparameter*.
- **Pengembangan DSS:** Mengintegrasikan model terbaik ke dalam dashboard interaktif (seperti *Streamlit*) untuk mendukung keputusan operasional secara langsung.

DAFTAR PUSTAKA

- [1] **Kluyver, T., et al. (2016).** *"Jupyter Notebooks – A Publishing Format for Reproducible Computational Workflows"*. IOS Press. (Referensi utama yang mendasari konsep dokumen interaktif yang menggabungkan kode dan narasi).
- [2] **Shim, J. P., Warkentin, M., Courtney, J. F., Power, D. J., Sharda, R., & Carlsson, C. (2002).** Past, present, and future of decision support systems. *Decision Support Systems*, 33(2), 111–126.
- [3] **Shaw, M. J., Subramaniam, C., Tan, G. W., & Welge, M. E. (2001).** Knowledge management and data mining for marketing decision support. *IEEE Transactions on Knowledge and Data Engineering*, 13(1), 63–74.
- [4] **Mitchell, T. M. (1997).** *Machine Learning*. McGraw-Hill.
- [5] **Bishop, C. M. (2006).** *Pattern recognition and machine learning*. Springer.
- [6] **Tan, P.-N., Steinbach, M., Karpapne, A., & Kumar, V. (2018).** *Introduction to Data Mining* (2nd ed.). Pearson.
- [7] **Han, J., Kamber, M., & Pei, J. (2011).** *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- [8] **Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016).** *Data Mining: Practical Machine Learning Tools and Techniques* (4th ed.). Morgan Kaufmann.
- [9] **McKinney, W. (2017).** *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.
- [10] **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011).** Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [11] **Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B. E., Bussonnier, M., Frederic, J., ... & Willing, C. (2016).** Jupyter Notebooks – a publishing format for reproducible computational workflows. In *Positioning and Power in Academic Publishing: Players, Agents and Agendas* (pp. 87–90). IOS Press.
- [12] **García, S., Luengo, J., & Herrera, F. (2015).** *Data Preprocessing in Data Mining*. Springer. <https://doi.org/10.1007/978-3-319-10247-4>
- [13] **Janiesch, C., Zschech, P., & Heinrich, K. (2021).** Machine learning and deep learning. *Electronic Markets*, 31(3), 685–695. <https://doi.org/10.1007/s12525-021-00475-2>.
- [14] **Aggarwal, C. C. (2015).** *Data Mining: The Textbook*. Springer. <https://doi.org/10.1007/978-3-319-14142-8>.